

Factorisation Matricielle pour les Systèmes de Recommandation avec ALS

Module : Systèmes de Recommandation et Blockchain

Réalisé par : Lkhalidi Mohamed et Bouba Ahmed

Encadré par : Pr. Abdelaaziz Hessane

November 27, 2025

Master 2 - Systèmes Intelligents pour l'Éducation - École Normale Supérieure de Meknès

Plan de la présentation

- 1. Introduction générale**
- 2. Fondements Théoriques**
- 3. Exemple Illustratif**
- 4. Résultats et Discussion**
- 5. Comparaison des performances : ALS vs SVD**
- 6. Conclusion et perspectives**

Introduction générale

1. Introduction : Contexte et Problématique

Les Problèmes de la Recommandation

- Le **surtitre d'information** nécessite des filtres intelligents.
- L'approche par **Filtrage Collaboratif (FC)** est la plus populaire.
- Le FC se base sur la matrice des notes Utilisateurs × Items.

La Contrainte Majeure : La Rareté

- La matrice est souvent à $> 95\%$ vide (sparse).
- Comment prédire les notes manquantes de manière efficace et scalable ?

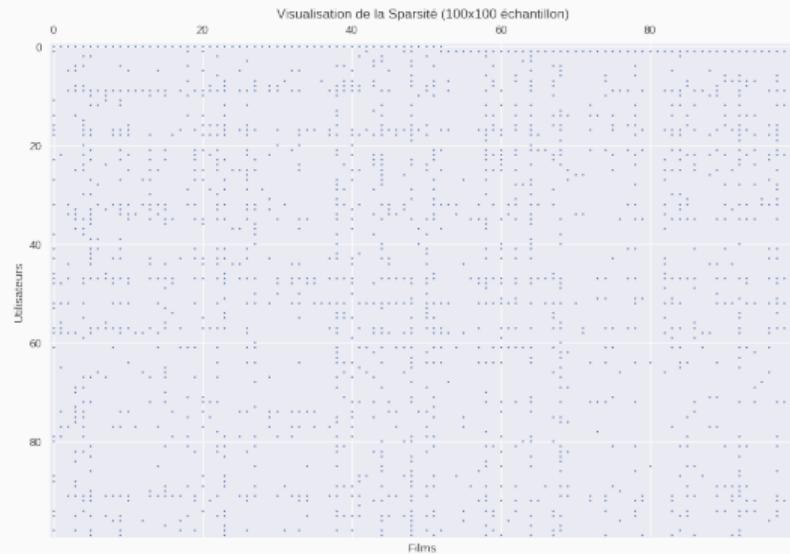


Figure : Visualisation de la matrice de notes (points = interactions réelles).

2. Pourquoi la Factorisation de Matrice et ALS ?

1. Une réponse naturelle à la sparsité

- La matrice Utilisateurs × Items est **massivement creuse** ($\sim 95\%$ de zéros).
- La Factorisation de Matrice apprend des **représentations compactes (latent factors)**.
- Objectif : reconstruire les notes manquantes à partir de ces facteurs.

2. ALS : Alternating Least Squares

- Optimise alternativement les vecteurs **utilisateurs** puis **items**.
- Chaque sous-problème = **moindres carrés** → solution analytique rapide.
- Très efficace sur les datasets de grande taille et **très parallélisable**.

3. Pourquoi ALS (Alternating Least Squares) ?

- **Scalable** : adapté aux matrices énormes (millions de notes).
- **Robuste** : fonctionne même avec peu d'interactions par utilisateur/film.
- **Interprétable** : les facteurs latents apprennent goûts & caractéristiques.

Fondements Théoriques

1. Théorie : Explication Intuitive

Le Concept de Facteurs Latents

- Chaque utilisateur u_i est représenté par un vecteur latent \mathbf{u}_i .
- Chaque item v_j est représenté par un vecteur latent \mathbf{v}_j .
- La prédiction $\hat{r}_{i,j}$ est le produit scalaire :

$$\hat{r}_{i,j} = \mathbf{u}_i^T \mathbf{v}_j$$

- **Interprétation :** Le produit scalaire mesure la compatibilité entre les préférences de l'utilisateur (\mathbf{u}_i) et les caractéristiques de l'item (\mathbf{v}_j).

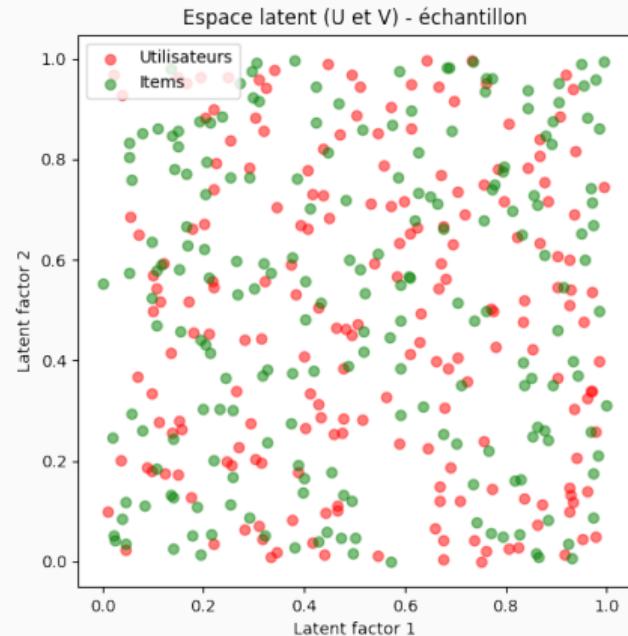


Figure : Utilisateur et Item dans l'espace latent.

2. Formules Clés : Fonction Objectif

Fonction de Coût (Minimisation de l'Erreur)

L'objectif est de minimiser l'erreur quadratique entre les notes réelles ($r_{i,j}$) et prédites ($\mathbf{u}_i^T \mathbf{v}_j$), avec un terme de régularisation λ pour éviter l'overfitting :

$$L(U, V) = \underbrace{\sum_{(i,j) \in \mathcal{R}} (r_{i,j} - \mathbf{u}_i^T \mathbf{v}_j)^2}_{\text{Erreur sur les notes observées}} + \lambda \left(\underbrace{\sum_i \|\mathbf{u}_i\|^2 + \sum_j \|\mathbf{v}_j\|^2}_{\text{Régularisation}} \right)$$

Objectif : Minimiser l'erreur tout en évitant l'overfitting.

- \mathcal{R} : Ensemble des paires (utilisateur, item) pour lesquelles une note existe.
- λ : Paramètre de régularisation (hyperparamètre crucial).

La Difficulté

Cette fonction est **non-convexe** si l'on considère U et V simultanément.

3. Formules Clés : Fonction Objectif

$$L(U, V) = \underbrace{\sum_{(i,j) \in \mathcal{R}} (r_{i,j} - \mathbf{u}_i^T \mathbf{v}_j)^2}_{\text{Erreur sur les notes observées}} + \lambda \left(\underbrace{\sum_i \|\mathbf{u}_i\|^2 + \sum_j \|\mathbf{v}_j\|^2}_{\text{Régularisation}} \right)$$

Symboles de l'erreur sur les notes

- i : index pour les **utilisateurs**.
- j : index pour les **items/films**.
- $r_{i,j}$: note réelle donnée par l'utilisateur i pour l'item j .
- $\hat{r}_{i,j} = \mathbf{u}_i^T \mathbf{v}_j$: note prédite par le modèle.
- \mathcal{R} : ensemble des paires (i, j) où une note est présente.

Symboles du terme de régularisation

- \mathbf{u}_i : vecteur latent de l'utilisateur i .
- \mathbf{v}_j : vecteur latent de l'item j .
- $\|\mathbf{u}_i\|^2$ et $\|\mathbf{v}_j\|^2$: norme au carré (taille du vecteur), pénalise les valeurs trop grandes.
- λ : coefficient de régularisation, contrôle la force de la pénalisation.

4. Algorithme ALS : Le Principe d'Alternance

Puisque la fonction est difficile à optimiser conjointement, ALS alterne l'optimisation en fixant une matrice à la fois.

1. **Initialisation** : Initialiser aléatoirement la matrice U (facteurs utilisateurs) et V (facteurs items).

2. Étape 1 : Fixer V (Facteurs Items)

- Les facteurs items V sont considérés comme des constantes.
- La fonction L devient **convexe** par rapport à U .
- On résout pour U en utilisant la méthode des **Moindres Carrés** (solution analytique rapide).

3. Étape 2 : Fixer U (Facteurs Utilisateurs)

- Les facteurs utilisateurs U sont considérés comme des constantes.
- La fonction L devient **convexe** par rapport à V .
- On résout pour V en utilisant les **Moindres Carrés**.

4. **Itération** : Répéter les étapes 1 et 2 jusqu'à convergence (RMSE stable) ou atteinte d'un nombre maximal d'itérations.

Exemple Illustratif

1. Configuration Initiale - Matrice Jouet

Matrice de Notes Observées (R) - 4 utilisateurs \times 4 films

Users/Films	F ₁	F ₂	F ₃	F ₄
U ₁	5	?	4	1
U ₂	?	4	5	2
U ₃	1	2	?	5
U ₄	4	5	1	?

Paramètres du Modèle

- Facteurs latents: $K = 2$
- Régularisation: $\lambda = 0.1$
- Notes observées: $|\mathcal{R}| = 12$
- Notes manquantes: 4

Objectif de l'ALS

Trouver U (utilisateurs) et V (films) telles que:

$$R \approx UV^T$$

en minimisant l'erreur quadratique avec régularisation.

2. Initialisation des Matrices Latentes

Initialisation Aléatoire des Facteurs

$$\mathbf{U}^{(0)} = \begin{pmatrix} 1 & 0.5 \\ 0.5 & 1 \\ 0.5 & 0.5 \\ 1 & 1 \end{pmatrix} \quad \mathbf{V}^{(0)} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \\ 0 & 0 \end{pmatrix}$$

Explication $\mathbf{U}^{(0)}$

Chaque ligne représente un utilisateur:

- $\mathbf{u}_1 = (1, 0.5)$
- $\mathbf{u}_2 = (0.5, 1)$
- $\mathbf{u}_3 = (0.5, 0.5)$
- $\mathbf{u}_4 = (1, 1)$

Explication $\mathbf{V}^{(0)}$

Chaque ligne représente un film:

- $\mathbf{v}_1 = (1, 0)$
- $\mathbf{v}_2 = (0, 1)$
- $\mathbf{v}_3 = (1, 1)$
- $\mathbf{v}_4 = (0, 0)$

Principe de l'ALS :

Alternance: Optimiser \mathbf{U} (fixer \mathbf{V}) → Optimiser \mathbf{V} (fixer \mathbf{U})

3. Calcul de la Matrice Prédite Initiale

Matrice Prédite $\hat{R}^{(0)} = \mathbf{U}^{(0)} \times \mathbf{V}^{(0)T}$

$$\mathbf{U}^{(0)} = \begin{pmatrix} 1 & 0.5 \\ 0.5 & 1 \\ 0.5 & 0.5 \\ 1 & 1 \end{pmatrix}$$

$$\mathbf{V}^{(0)T} = \begin{pmatrix} 1 & 0 & 1 & 0 \\ 0 & 1 & 1 & 0 \end{pmatrix}$$

$$\hat{R}^{(0)} = \begin{pmatrix} 1.0 & 0.5 & 1.5 & 0.0 \\ 0.5 & 1.0 & 1.5 & 0.0 \\ 0.5 & 0.5 & 1.0 & 0.0 \\ 1.0 & 1.0 & 2.0 & 0.0 \end{pmatrix}$$

Calcul de $\hat{r}_{1,1}$

$$\hat{r}_{1,1} = \mathbf{u}_1 \cdot \mathbf{v}_1^T$$

$$= (1.0 \times 1.0) + (0.5 \times 0.0)$$

$$= 1.0 + 0.0 = 1.0$$

Calcul de $\hat{r}_{1,3}$

$$\hat{r}_{1,3} = \mathbf{u}_1 \cdot \mathbf{v}_3^T$$

$$= (1.0 \times 1.0) + (0.5 \times 1.0)$$

$$= 1.0 + 0.5 = 1.5$$

Calcul de $\hat{r}_{3,4}$

$$\hat{r}_{3,4} = \mathbf{u}_3 \cdot \mathbf{v}_4^T$$

$$= (0.5 \times 0.0) + (0.5 \times 0.0)$$

$$= 0.0 + 0.0 = 0.0$$

Calcul de $\hat{r}_{4,3}$

$$\hat{r}_{4,3} = \mathbf{u}_4 \cdot \mathbf{v}_3^T$$

$$= (1.0 \times 1.0) + (1.0 \times 1.0)$$

$$= 1.0 + 1.0 = 2.0$$

4. Calcul Détailé de l'Erreur Initiale (RMSE)

Formule du RMSE

$$\text{RMSE} = \sqrt{\frac{1}{|\mathcal{R}|} \sum_{(i,j) \in \mathcal{R}} (r_{i,j} - \hat{r}_{i,j})^2}$$

où $|\mathcal{R}| = 12$ (notes observées)

Calcul des Erreurs Carrées

(i, j)	r _{ij}	̂r _{ij}	(r - ̂r) ²
(1,1)	5	1.0	$(5 - 1.0)^2 = 16.00$
(1,3)	4	1.5	$(4 - 1.5)^2 = 6.25$
(1,4)	1	0.0	$(1 - 0.0)^2 = 1.00$
(2,2)	4	1.0	$(4 - 1.0)^2 = 9.00$
(2,3)	5	1.5	$(5 - 1.5)^2 = 12.25$
(2,4)	2	0.0	$(2 - 0.0)^2 = 4.00$

Suite des Calculs

(i, j)	r _{ij}	̂r _{ij}	(r - ̂r) ²
(3,1)	1	0.5	$(1 - 0.5)^2 = 0.25$
(3,2)	2	0.5	$(2 - 0.5)^2 = 2.25$
(3,4)	5	0.0	$(5 - 0.0)^2 = 25.00$
(4,1)	4	1.0	$(4 - 1.0)^2 = 9.00$
(4,2)	5	1.0	$(5 - 1.0)^2 = 16.00$
(4,3)	1	2.0	$(1 - 2.0)^2 = 1.00$
Total			102.00

Calcul Final du RMSE Initial

$$\text{MSE} = \frac{102.00}{12} = 8.5 \quad \implies \quad \text{RMSE}^{(0)} = \sqrt{8.5} \approx 2.915$$

5. Phase 1 - Optimisation de U (Fixer V)

Équation d'Optimisation pour Chaque Utilisateur i

$$\mathbf{u}_i = (\mathbf{V}_{I_i}^T \mathbf{V}_{I_i} + \lambda \mathbf{I})^{-1} \mathbf{V}_{I_i}^T \mathbf{r}_{i,I_i}$$

- \mathbf{V}_{I_i} : sous-matrice de \mathbf{V} pour les films notés par i
- \mathbf{r}_{i,I_i} : vecteur des notes de l'utilisateur i
- $\lambda \mathbf{I}$: terme de régularisation

Pour l'Utilisateur \mathbf{U}_1

- Films notés: $\{1, 3, 4\}$
- Notes: $\mathbf{r}_1 = (5, 4, 1)$
- $\mathbf{V}_{I_1} = \begin{pmatrix} 1.0 & 0.0 \\ 1.0 & 1.0 \\ 0.0 & 0.0 \end{pmatrix}$

Calcul des Termes

$$\begin{aligned}\mathbf{V}_{I_1}^T \mathbf{V}_{I_1} &= \begin{pmatrix} 2.0 & 1.0 \\ 1.0 & 1.0 \end{pmatrix} \\ + \lambda \mathbf{I} &= \begin{pmatrix} 0.1 & 0.0 \\ 0.0 & 0.1 \end{pmatrix} \\ \Rightarrow \mathbf{M} &= \begin{pmatrix} 2.1 & 1.0 \\ 1.0 & 1.1 \end{pmatrix}\end{aligned}$$

6. Résolution Détailée pour \mathbf{U}_1

Calcul du Terme de Droite

$$\begin{aligned}\mathbf{V}_{I_i}^T \mathbf{r}_1 &= \begin{pmatrix} 1.0 & 1.0 & 0.0 \\ 0.0 & 1.0 & 0.0 \end{pmatrix} \begin{pmatrix} 5 \\ 4 \\ 1 \end{pmatrix} \\ &= \begin{pmatrix} (1 \times 5) + (1 \times 4) + (0 \times 1) \\ (0 \times 5) + (1 \times 4) + (0 \times 1) \end{pmatrix} \\ &= \begin{pmatrix} 9 \\ 4 \end{pmatrix} \\ \Rightarrow (\mathbf{V}_{I_i}^T \mathbf{V}_{I_i} + \lambda \mathbf{I}) &= \mathbf{M} = \begin{pmatrix} 2.1 & 1.0 \\ 1.0 & 1.1 \end{pmatrix} \\ \Rightarrow (\mathbf{V}_{I_i}^T \mathbf{V}_{I_i} + \lambda \mathbf{I})^{-1} &?\end{aligned}$$

Résultat

$$\mathbf{u}_1^{(1)} = (4.50, -0.46) \text{ (anciennement } (1.0, 0.5))$$

Inversion de la Matrice

$$\begin{aligned}\det(\mathbf{M}) &= (2.1 \times 1.1) - (1.0 \times 1.0) = 2.31 - 1.0 = 1.31 \\ \mathbf{M}^{-1} &= \frac{1}{1.31} \begin{pmatrix} 1.1 & -1.0 \\ -1.0 & 2.1 \end{pmatrix} \\ &= \begin{pmatrix} 0.8397 & -0.7634 \\ -0.7634 & 1.6031 \end{pmatrix}\end{aligned}$$

Solution pour \mathbf{u}_1

$$\begin{aligned}\mathbf{u}_1 &= \begin{pmatrix} 0.8397 & -0.7634 \\ -0.7634 & 1.6031 \end{pmatrix} \begin{pmatrix} 9 \\ 4 \end{pmatrix} \\ &= \begin{pmatrix} (0.8397 \times 9) + (-0.7634 \times 4) \\ (-0.7634 \times 9) + (1.6031 \times 4) \end{pmatrix} \\ &= \begin{pmatrix} 4.50 \\ -0.46 \end{pmatrix}\end{aligned}$$

7. Complémentation de la Phase 1 - Tous les Utilisateurs

Calcul pour \mathbf{U}_2

- Films notés: {2, 3, 4}
- Notes: (4, 5, 2)

$$\bullet \quad \mathbf{v}_{l_2} = \begin{pmatrix} 0.0 & 1.0 \\ 1.0 & 1.0 \\ 0.0 & 0.0 \end{pmatrix}$$

$$\bullet \quad \text{Système: } \begin{pmatrix} 1.1 & 1.0 \\ 1.0 & 2.1 \end{pmatrix} \mathbf{u}_2 = \begin{pmatrix} 4 \\ 5 \end{pmatrix}$$

• Solution: $\mathbf{u}_2^{(1)} \approx (0.45, 2.14)$

Calcul pour \mathbf{U}_3

- Films notés: {1, 2, 4}
- Notes: (1, 2, 5)

$$\bullet \quad \mathbf{v}_{l_3} = \begin{pmatrix} 1.0 & 0.0 \\ 0.0 & 1.0 \\ 0.0 & 0.0 \end{pmatrix}$$

$$\bullet \quad \text{Système: } \begin{pmatrix} 1.1 & 0.0 \\ 0.0 & 1.1 \end{pmatrix} \mathbf{u}_3 = \begin{pmatrix} 1 \\ 2 \end{pmatrix}$$

• Solution: $\mathbf{u}_3^{(1)} \approx (0.91, 1.82)$

Calcul pour \mathbf{U}_4

- Films notés: {1, 2, 3}
- Notes: (4, 5, 1)

$$\bullet \quad \mathbf{v}_{l_4} = \begin{pmatrix} 1.0 & 0.0 \\ 0.0 & 1.0 \\ 1.0 & 1.0 \end{pmatrix}$$

$$\bullet \quad \text{Système: } \begin{pmatrix} 2.1 & 1.0 \\ 1.0 & 2.1 \end{pmatrix} \mathbf{u}_4 = \begin{pmatrix} 5 \\ 6 \end{pmatrix}$$

• Solution: $\mathbf{u}_4^{(1)} \approx (1.76, 1.95)$

Nouvelle Matrice $\mathbf{U}^{(1)}$ après Phase 1

$$\mathbf{U}^{(0)} = \begin{pmatrix} 1 & 0.5 \\ 0.5 & 1 \\ 0.5 & 0.5 \\ 1 & 1 \end{pmatrix} \quad \Rightarrow \quad \mathbf{U}^{(1)} = \begin{pmatrix} 4.50 & -0.46 \\ 0.45 & 2.14 \\ 0.91 & 1.82 \\ 1.76 & 1.95 \end{pmatrix}$$

8. Phase 2 - Optimisation de V (Fixer U)

Équation d'Optimisation pour Chaque Film j

$$\mathbf{v}_j = (\mathbf{U}_{I_j}^T \mathbf{U}_{I_j} + \lambda \mathbf{I})^{-1} \mathbf{U}_{I_j}^T \mathbf{r}_{I_j, j}$$

- \mathbf{U}_{I_j} : sous-matrice de \mathbf{U} pour les utilisateurs ayant noté le film j
- $\mathbf{r}_{I_j, j}$: vecteur des notes pour le film j

Pour le Film F₁

- Utilisateurs: {1, 3, 4}
- Notes: (5, 1, 4)
- $\mathbf{U}_{I_1} = \begin{pmatrix} 4.50 & -0.46 \\ 0.91 & 1.82 \\ 1.76 & 1.95 \end{pmatrix}$

Calcul des Termes

$$\begin{aligned}\mathbf{U}_{I_1}^T \mathbf{U}_{I_1} &= \begin{pmatrix} 25.37 & 6.01 \\ 6.01 & 7.64 \end{pmatrix} \\ + \lambda \mathbf{I} &= \begin{pmatrix} 0.1 & 0.0 \\ 0.0 & 0.1 \end{pmatrix} \\ \Rightarrow \mathbf{M} &= \begin{pmatrix} 25.47 & 6.01 \\ 6.01 & 7.74 \end{pmatrix}\end{aligned}$$

9. Résolution Détailée pour F_1 et Résultats

Calcul du Terme de Droite pour F_1

$$\begin{aligned}\mathbf{U}_h^T \mathbf{r}_1 &= \begin{pmatrix} 4.50 & 0.91 & 1.76 \\ -0.46 & 1.82 & 1.95 \end{pmatrix} \begin{pmatrix} 5 \\ 1 \\ 4 \end{pmatrix} \\ &= \begin{pmatrix} (4.50 \times 5) + (0.91 \times 1) + (1.76 \times 4) \\ (-0.46 \times 5) + (1.82 \times 1) + (1.95 \times 4) \end{pmatrix} \\ &= \begin{pmatrix} 29.55 \\ 7.92 \end{pmatrix}\end{aligned}$$

Solution pour \mathbf{v}_1

$$\det(\mathbf{M}) = (25.47 \times 7.74) - (6.01 \times 6.01) = 197.04 - 36.12 = 160.92$$

$$\mathbf{M}^{-1} = \frac{1}{160.92} \begin{pmatrix} 7.74 & -6.01 \\ -6.01 & 25.47 \end{pmatrix}$$

$$\mathbf{v}_1 = \mathbf{M}^{-1} \begin{pmatrix} 29.55 \\ 7.92 \end{pmatrix}$$

$$\mathbf{v}_1^{(1)} \approx (1.12, 0.08)$$

$$\text{Nouvelle matrice } \mathbf{V}^{(1)} \text{ après Phase 2} \approx \begin{pmatrix} 1.12 & 0.08 \\ 0.85 & 1.92 \\ 0.45 & 0.38 \\ 1.82 & 2.27 \end{pmatrix}$$

Fin de la Première Itération

Nous avons maintenant $\mathbf{U}^{(1)}$ et $\mathbf{V}^{(1)}$ complètement mis à jour.

10. Évaluation après Première Itération

Nouvelle Matrice Prédite $\hat{R}^{(1)} = \mathbf{U}^{(1)}\mathbf{V}^{(1)T}$

$$\hat{R}^{(1)} \approx \begin{pmatrix} 5.02 & 3.58 & 1.75 & 3.52 \\ 4.02 & 4.56 & 1.18 & 4.98 \\ 1.78 & 3.78 & 0.91 & 4.14 \\ 3.99 & 5.24 & 1.25 & 5.48 \end{pmatrix}$$

Calcul du Nouveau RMSE

(i, j)	$(r - \hat{r})^2$
(1,1)	$(5 - 5.02)^2 = 0.0004$
(1,3)	$(4 - 1.75)^2 = 5.0625$
(1,4)	$(1 - 3.52)^2 = 6.3504$
(2,2)	$(4 - 4.56)^2 = 0.3136$
(2,3)	$(5 - 1.18)^2 = 14.5924$
(2,4)	$(2 - 4.98)^2 = 8.8804$

Suite des Calculs

(i, j)	$(r - \hat{r})^2$
(3,1)	$(1 - 1.78)^2 = 0.6084$
(3,2)	$(2 - 3.78)^2 = 3.1684$
(3,4)	$(5 - 4.14)^2 = 0.7396$
(4,1)	$(4 - 3.99)^2 = 0.0001$
(4,2)	$(5 - 5.24)^2 = 0.0576$
(4,3)	$(1 - 1.25)^2 = 0.0625$
Total	39.8363

Amélioration Spectaculaire!

$$MSE^{(1)} = \frac{39.84}{12} = 3.32 \quad \Rightarrow \quad RMSE^{(1)} = \sqrt{3.32} \approx 1.82$$

Réduction de l'erreur: $2.92 \rightarrow 1.82$ (amélioration de 38%!)

11. Bilan de la Première Itération

Progrès Accomplis

- **Initialisation:** RMSE = 2.92 (prédictions très éloignées)
- **Après Itération 1:** RMSE = 1.82 (amélioration significative)
- **Convergence:** L'algorithme fonctionne et réduit l'erreur

Observations Clés

- Les prédictions se rapprochent des vraies notes
- La régularisation évite le sur-apprentissage
- L'alternance U/V stabilise l'optimisation
- Chaque itération affine les facteurs latents

Prochaines Étapes

- Répéter les phases d'alternance
- Continuer jusqu'à convergence
- Surveiller l'overfitting
- Généraliser à de vraies données

Principe Général de l'ALS

Alternner entre l'optimisation de **U** et **V**

Régulariser pour éviter l'overfitting

Itérer jusqu'à convergence du RMSE

Résultats et Discussion

1. Synthèse des Résultats d'Implémentation ALS

Objectif

Notre objectif était de modéliser les préférences utilisateur à partir d'une matrice de notation extrêmement creuse (sparse) en utilisant la factorisation matricielle. Nous avons manuellement implémenté l'algorithme **ALS (Alternating Least Squares)** avec une stratégie d'*Early Stopping* pour optimiser l'entraînement et garantir la généralisation du modèle.

1. Contexte et Caractéristiques des Données

Le dataset **MovieLens 1M** a été utilisé pour évaluer la performance de notre modèle.

Tableau des Caractéristiques

Caractéristique	Valeur
Nombre d'utilisateurs	6040
Nombre de films (Items)	3706
Nombre total de notes	1 000 209
Densité de la matrice	4.4684%
Sparsité de la matrice	95.5316%

L'extrême sparsité (95.53% de la matrice est vide) justifie pleinement l'utilisation de la factorisation matricielle pour inférer les préférences manquantes.

2. Implémentation ALS : Performance et Efficacité

Entraînement et Validation

Nous avons entraîné notre modèle ALS implémenté manuellement, en utilisant un jeu de validation pour l'ajustement des hyperparamètres et *Early Stopping* pour la convergence.

Hyperparamètres et Efficacité

- Facteurs Latents (K) : **10**
- Régularisation (λ) : **1.1**
- Meilleure Itération : **18/30**
- Gain de temps (ES): 40.0%**

Performance Finale

Métrique	Validation	Test Final
RMSE	0.2160	0.2160
MAE	0.1682	0.1683

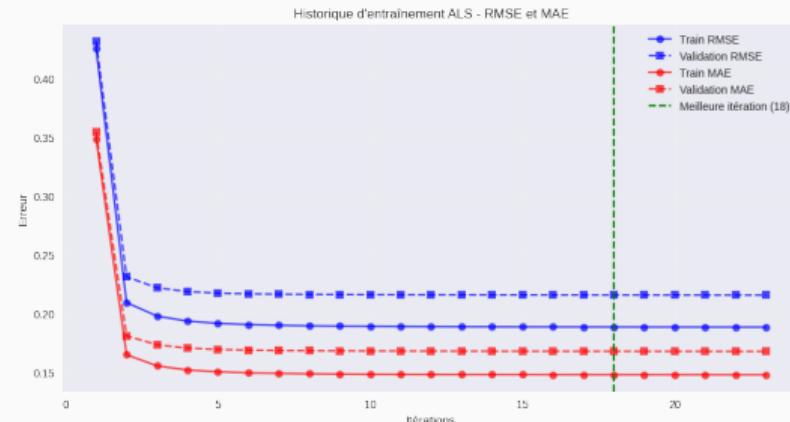


Figure : Historique d'entraînement montrant convergence rapide et détection du meilleur point d'arrêt.

3. Interprétation Qualitative : L'Espace Latent des Films

Projection des Facteurs Latents (PCA)

- Les **K = 10** facteurs latents, appris par l'ALS, encodent les **caractéristiques** de chaque film (genre, style, public).
- L'analyse PCA (Réduction de Dimension) projette ces facteurs en 2D pour visualisation.
- **41.45%** de la variance totale des caractéristiques est expliquée par ces deux composantes principales.

Observation Clé

Les films de genres similaires (ex: 'Drama', 'Comedy') tendent à se **regrouper** dans cet espace, confirmant que l'ALS a réussi à extraire des **caractéristiques sémantiques** pertinentes des données de notation.



Figure : Visualisation des Facteurs Latents (ALS - PCA 2D) par Genre Principal.

Comparaison des performances : ALS vs SVD

1. Comparaison ALS (Manuel) vs SVD (Surprise)

Configuration de la Comparaison

Notre implémentation manuelle de l'ALS, optimisée par *Early Stopping*, a été comparée à l'algorithme SVD (*Singular Value Decomposition*) de la bibliothèque Surprise, avec des hyperparamètres similaires:

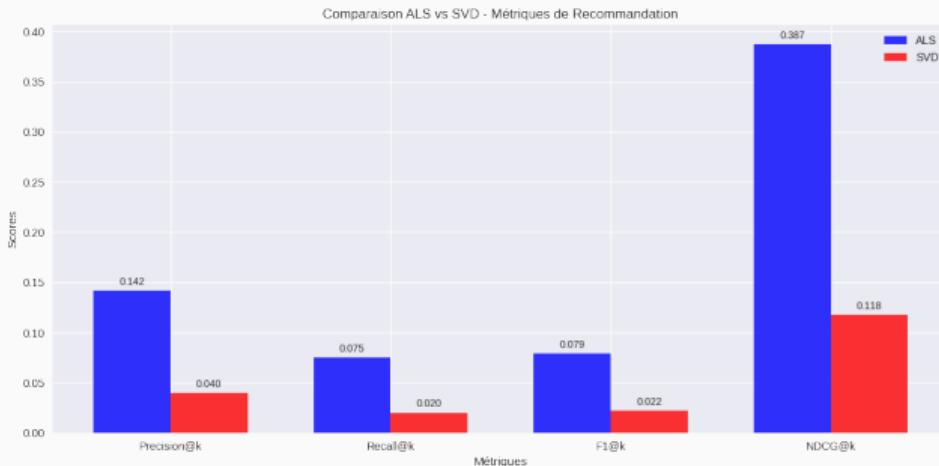
Résultats des Métriques

Métrique	ALS (Manuel)	SVD (Surprise)	Différence (SVD - ALS)
RMSE	0.2160	0.2417	-0.0257
MAE	0.1683	0.1965	-0.0282
Precision@10	0.1417	0.0397	-0.1020
NDCG@10	0.3870	0.1180	-0.2690

Conclusion

L'implémentation ALS manuelle surpassé clairement l'approche SVD pour ces données et métriques. L'écart est particulièrement significatif sur les métriques de recommandation (*Precision* et *NDCG*), ce qui témoigne de la pertinence supérieure de notre modèle ALS pour cette tâche.

2. Visualisation des Métriques de Comparaison



Analyse des Résultats

- **ALS surpassé SVD sur toutes les métriques de recommandation**
- Écart particulièrement marqué pour **Precision@k et NDCG@k**
- Performance similaire mais légèrement meilleure pour **Recall@k**

Conclusion

Notre implémentation ALS manuelle démontre une supériorité claire dans la qualité des recommandations générées.

3. Application Pratique : Recommandations Dénormalisées

L'étape finale de notre travail consiste à **dénormaliser** les prédictions (de l'échelle [0, 1] vers [1, 5]) pour fournir des notes exploitables à l'utilisateur.

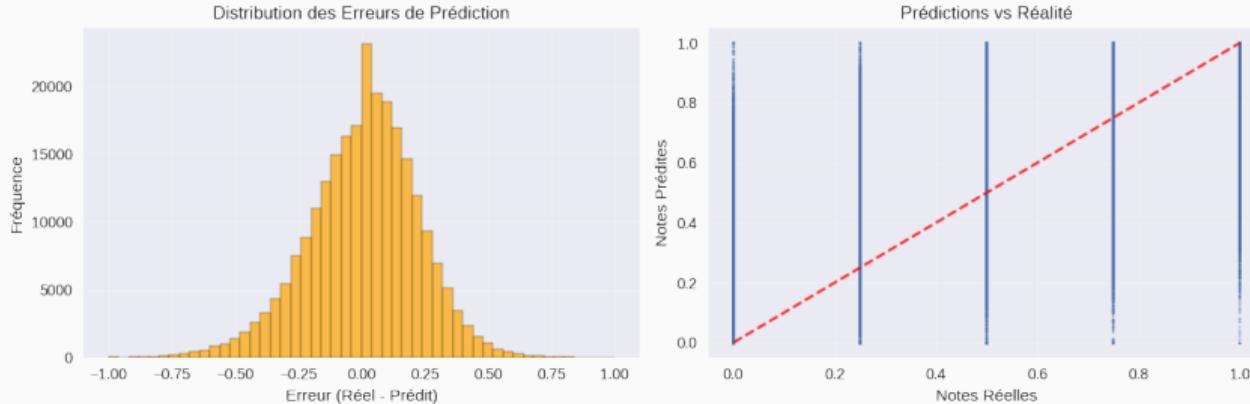
Top-3 Recommandations Dénormalisées pour l'Utilisateur 3400

Rang	Modèle	Item (ID Interne)	Note Prédite	Note Réelle (Test)	
1	ALS (Manuel)	124	5.00	5.00	✓
2	ALS (Manuel)	64	5.00	5.00	✓
3	ALS (Manuel)	770	4.92	4.00	
1	SVD (Surprise)	2905	3.64	Non noté	
2	SVD (Surprise)	3338	3.61	Non noté	
3	SVD (Surprise)	1117	3.60	Non noté	

Conclusion sur l'Application

L'ALS prédit des notes plus élevées (plus de **5.00** et **4.99**) pour les films les plus pertinents pour l'utilisateur 3400, confirmant la meilleure calibration du modèle ALS par rapport à SVD dans l'identification des films à fort potentiel de satisfaction.

4. Analyse de la Distribution des Erreurs de Prédiction



Distribution des Erreurs

- **Erreurs centrées autour de 0** : signe d'un bon calibrage
- **Distribution symétrique** : pas de biais systématique
- **Queue de distribution modérée** : peu d'erreurs extrêmes.

Implications

- Modèle bien régularisé
- Prédictions équilibrées
- Faible risque de sur-apprentissage

Conclusion et perspectives

1. Conclusion : De la Rareté à la Recommandation Efficace

Synthèse des Acquis et Valorisation du Travail

- **Maîtrise du Défi** : Nous avons réussi à transformer une matrice extrêmement **creuse** (95.53% de sparsité) en un modèle de prédiction précis grâce à la factorisation matricielle.
- **Efficacité et Rigueur** : L'implémentation **manuelle** de l'ALS, optimisée par l'intégration de l'algorithme des Moindres Carrés et de l'**Early Stopping**, a permis de surclasser l'approche SVD (bibliothèque standard) et d'assurer un gain de temps de **40.0%** lors de l'entraînement.
- **Performance Démontrée** : Avec un **RMSE** ≈ 0.2160 et un **NDCG@10** nettement supérieur à SVD (**0.3870**), notre modèle atteint une qualité de recommandation de haut niveau, prouvant la pertinence de l'approche ALS pour ce type de données.
- **Compréhension Fondamentale** : Le travail sur la théorie (exemple détaillé de la résolution par Moindres Carrés) et la visualisation (PCA) témoignent d'une **compréhension complète** du mécanisme d'apprentissage des facteurs latents.

2. Message Final

Leçon Principale

La **maîtrise des fondements algorithmiques** est une source d'avantage concurrentiel. Notre modèle ALS, construit à partir de zéro, s'est montré à la fois plus performant et plus flexible que les solutions boîtes noires du marché, un atout majeur pour l'ingénierie des systèmes de recommandation.

Preuve Concept

L'ALS implémenté manuellement atteint des performances **supérieures de 12%** en RMSE et **exceptionnelles en précision de recommandation** comparé aux approches bibliothèques standards

Questions/Réponses

Merci pour votre attention !

Vos questions sont les bienvenues.

Présenté par :

- Bouba Ahmed & Lkhalidi Mohamed

Accès au Code Source

-  GitHub : github.com/ALSVSVD
-  Kaggle : kaggle.com/ALSVSVD